

Estimation ponctuelle

Charles Vin

Date

1 Introduction

Diapo osez un peu

2 Modèle Statistique

- On collecte les données :
- On note x_1, x_2, \dots, x_n les réalisations
- des variables aléatoire X_1, X_2, \dots, X_n
- $x_1 = X_1, \dots, x_n = X_n$

Hypothèse : On suppose X_1, \dots, X_n indépendante et de même loi P (on dit "i.i.d.")

Objectif : Estimer P (difficile) à partir de X_1, \dots, X_n

Définition 2.1 (Modèle statistique). On appelle modèle statistique la donnée du triplet (Ω, F, P_θ) (θ est un paramètre.) où Ω = espace des observations, F tribu sur Ω , $P_{\theta \in \Theta}$ est une famille de probabilité définie sur (Ω, F) , θ = espace des paramètres.

Exemple 2.1. On souhaite tester l'efficacité d'un médicament. On traite n patients (individus statistique). A l'issue de l'étude 72 patients sont guéris.

Modélisation Statistique : On note $x_i = \begin{cases} 1 \\ 0 \end{cases}$ Si guéris ou non. x_i est une réalisation d'une VA de Bernoulli $\mathcal{B}(p)$, $p \in]0, 1[$, $\Omega = \{0, 1\}$, $F = \mathcal{P}(\{0, 1\})$ et la famille de probabilité est $\mathcal{B}(p)$, $p (= \theta) \in]0, 1[(= \Theta)$
Objectif : Reconstruire ou estimer ce paramètre p à l'aide de X_1, \dots, X_n

Exemple 2.2 (Nombre de voiture au feu). C'est un modèle de Poisson avec :

$$\Omega = \mathbb{N}, F = \mathcal{P}(\mathbb{N}), (P(\lambda), \lambda > 0) \text{ avec } P_\lambda[X = k] = e^{-\lambda} \frac{\lambda^k}{k!}.$$

Le paramètre est $\lambda \in \mathbb{R}_+^*$ \mathbb{R}_+^* est le Ω

Exemple 2.3 (Durée du trajet). Modèle gaussien :

$$\Omega = \mathbb{R}, F = \mathcal{B}(\mathbb{R}), (\mathcal{N}(m, \sigma^2), (m, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*).$$

3 Estimateur et propriétés

Définition 3.1 (n-échantillon). On appelle n-échantillon (échantillon de taille n) associé au modèle $(\Omega, F, (P_\theta)_{\theta \in \Theta})$ une suite X_1, \dots, X_n de va i.i.d. de même loi P_θ

Définition 3.2 (moyenne empirique). On appelle moyenne empirique la va

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Définition 3.3 (Variance empirique). On appelle variance empirique la va

$$V_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2.$$

Définition 3.4 (Statistique). On appelle statistique toute application de Ω^n dans R^p

Définition 3.5 (Estimateur). On appelle estimateur du paramètre θ toute statistique à valeur dans Θ

Remarque. Une statistique est une VA qui ne dépend que de X_1, \dots, X_n et a sa propre loi de probabilité.

Exemple 3.1. Exemple du traitement

- \hat{p}_1 est un estimateur de p .
- $\hat{p}_2 = \frac{1}{n} \sum_{i=1}^n X_i$ est un estimateur de p (car entre 0 et 1)
- $S_n = \sum_{i=1}^n X_i$ est une statistique (car dans R)

Théorème 3.1. X_1, \dots, X_n i.i.d. de loi commune $(P_\theta)_{\theta \in \Theta}$. Soit $m_\theta = \mathbb{E}_\theta[X_1]$ (espérance de X_1 pour P_θ), $\sigma_\theta^2 = \text{Var}_{\Theta(X_1)}$ (variance de X_1 pour P_Θ).

La moyenne empirique $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ est un estimateur de m_θ .

La variance empirique $V_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ est un estimateur de σ_θ^2

Définition 3.6 (Le moment empirique simple). Le moment empirique simple d'ordre $k, k \in N$ noté $\hat{m}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ est un estimateur du moment théorique d'ordre $k \in N^*$, $m_k(\theta) = \mathbb{E}_\theta(X_1^k)$

Définition 3.7 (Le moment empirique centré d'ordre k). Le moment empirique centré d'ordre k se note $\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X}_n)^k$ est un estimateur de $\mu_k(\Theta) = \mathbb{E}_\theta((X_1 - \mathbb{E}_\theta(X_1))^k)$

Note. La question est de savoir quel estimateur choisir!

4 Critère de performance

Soit T_n un estimateur de θ .

Définition 4.1. T_n est un estimateur sans biais du paramètre θ si $\mathbb{E}_\theta(T_n) = \theta$ (en moyenne on tombe sur le vrais paramètre).

T_n est un estimateur biaisé de θ si $\mathbb{E}_\theta(T_n) \neq \theta$

La quantité $\mathcal{B}_\theta(T_n) = \mathbb{E}_\theta(T_n) - \theta$ est appelé **biais de l'estimateur** en θ

Un estimateur T_n de θ est dit asymptotiquement sans biais si $\lim_{n \rightarrow +\infty} \mathbb{E}_\theta(T_n) = \theta$.

Distribution d'un estimateur T_n sans biais de θ

Distribution d'un estimateur biaisé T_n de θ VOIR DIAPO

Cadre général : X_1, X_2, \dots, X_n i.i.d. de loi $P_\theta, \theta \in \Theta$ avec $m_\theta = E_\theta(X_1)$ et $\sigma_\theta^2 = \text{var}_\theta(X_1)$.

Théorème 4.1. La moyenne empirique $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ est un estimateur sans biais de m_θ . En effet :

$$\begin{aligned} E_\theta\left(\frac{1}{n} \sum_{i=1}^n X_i\right) &= \frac{1}{n} \sum_{i=1}^n E_\theta(X_i) \\ &= \frac{1}{n} n E_\theta(X_1) \\ &= m_\theta \end{aligned}$$

Exemple 4.1. X_1, \dots, X_n i.i.d. de loi $\text{Exp}(\lambda)$ avec $\lambda > 0$. On a

- $E_\lambda(X_1) = \frac{1}{\lambda}$
- $\text{Var}_\lambda(X_1) = \frac{1}{\lambda^2}$
- λ inconnu

$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ est un estimateur sans biais de $\frac{1}{\lambda}$ ($\frac{1}{\bar{X}_n}$ est un estimateur de λ)

Exemple 4.2. X_1, \dots, X_n i.i.d. de loi $\mathcal{P}(\lambda)$ avec $\lambda > 0$.

$$\forall k \in N, P_\lambda(X_1 = k) = e^{-\lambda} \frac{\lambda^k}{k!}, E_\lambda(X_1) = \lambda.$$

Théorème 4.2. La **variance empirique** $V_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ est un estimateur biaisé de σ_θ^2 .
La **variance empirique corrigée** $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ est un estimateur sans biais de σ_θ^2

Preuve : On doit montrer que $E_\theta(V_n^2) \neq \sigma_\theta^2$. On a

$$E_\theta(V_n^2) = E_\theta\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2\right).$$

Or

$$\begin{aligned} V_n^2 &= \frac{1}{n} \sum_{i=1}^n (X_i^2 - 2X_i\bar{X}_n + \bar{X}_n^2) \\ &= \frac{1}{n} \sum_{i=1}^n X_i^2 - 2\bar{X}_n\left(\frac{1}{n} \sum_{i=1}^n X_i\right) + \bar{X}_n^2 \\ &= \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \end{aligned}$$

$$\begin{aligned} E_\theta(V_n^2) &= E_\theta\left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2\right) \\ &= \frac{1}{n} \sum_{i=1}^n E_\theta(X_i^2) - E_\theta(\bar{X}_n^2) \\ &= \frac{1}{n} * nE_\theta(X_1^2) - E_\theta(\bar{X}_n^2) \text{ car mes } X_i \text{ ont la même loi} \\ &= E_\theta(V_n^2) = E_\theta(X_1^2) - E_\theta(\bar{X}_n^2) \end{aligned}$$

Finally :

$$\begin{aligned} \text{Var}_\theta(X_1) &= E_\theta(X_1^2) - E_\theta^2(X_1) \Leftrightarrow \sigma_\theta^2 = E_\theta(X_1^2) - m_\theta^2. \\ &\Leftrightarrow E_\theta(X_1^2) = \sigma_\theta^2 + m_\theta^2. \end{aligned}$$

De la même façon, on a

$$E(X_n^2) = \text{var}(\bar{X}_n) + E^2(\bar{X}_n).$$

et

$$\begin{aligned} \text{Var}_\theta(\bar{X}_n) &= \text{Var}_\theta\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \left(\frac{1}{n}\right)^2 \text{Var}_\theta\left(\sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}_\theta(X_i) \text{ car les } X_i \text{ sont indépendante} \\ &= \frac{1}{n^2} n \text{Var}_\theta(X_1) \text{ car les } X_i \text{ ont la même loi} \end{aligned}$$

Conclusion :

$$\text{Var}_\theta(\bar{X}_n) = \frac{\text{Var}_\theta(X_1)}{n} = \frac{\sigma_\theta^2}{n}.$$

On obtient

$$\begin{aligned} E_\theta(V_n^2) &= E_\theta(X_1^2) - (\text{Var}_\theta(X_n) + E_\theta^2(\bar{X}_n)) \\ &= (\sigma_\theta^2 + m_\theta^2) - \left(\frac{\sigma_\theta^2}{n} + m_\theta^2\right) \\ &= \sigma_\theta^2 - \frac{\sigma_\theta^2}{n} \neq \sigma_\theta^2 \\ & (V_n^2 \text{ est un estimateur biaisé de } \sigma_\theta^2) \end{aligned}$$

Le biais de V_n^2 en $B_\theta(V_n^2) = E_\theta(V_n^2) - \sigma_\theta^2 = -\frac{\sigma_\theta^2}{n}$.

On corrige l'estimateur V_n^2 :

$$E_\theta(V_n^2) = \frac{n-1}{n} \sigma_\theta^2$$

$$E_\theta\left(\frac{n}{n-1} V_n^2\right) = \sigma_\theta^2$$

$$\begin{aligned} S_n^2 &= \frac{n}{n-1} V_n^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \end{aligned}$$

est un estimateur sans biais de σ_θ^2 .

V_n^2 est un estimateur asymptotiquement sans biaisés de σ_θ^2 car :

$$\lim_{n \rightarrow \infty} E_\theta(V_n^2) = \sigma_\theta^2.$$

□

Exemple 4.3. X_1, \dots, X_n i.i.d. de loi $Exp(\lambda)$, $\lambda > 0$.

On a $\sigma_\lambda^2 = Var_\lambda(X_1) = \frac{1}{\lambda^2}$

$S_n^2 = \frac{1}{n-1} \sum (X_i - \bar{X}_n)^2$ est i, estimateur sans biais de $\frac{1}{\lambda^2}$

V_n^2 est un estimateur biaisé de $\frac{1}{\lambda^2}$

Définition 4.2 (Risque quadratique). — Soit T_n un estimateur de θ , on appelle **Risque quadratique** de l'estimateur T_n (=erreur quadratique moyenne) la quantité définie par

$$\mathcal{R}(\theta, T_n) = E_\theta[(T_n - \theta)^2].$$

— Soit T_n et T'_n deux estimateur de θ , T_n est dit **préférable** à T'_n si

$$\mathcal{R}(\theta, T_n) < \mathcal{R}(\theta, T'_n), \forall \theta \in \Theta.$$

Remarque. On a la décomposition :

$$\mathcal{R}(\theta, T_n) = Var_\theta(T_n) + (E_\theta(T_n) - \theta)^2.$$

Lorsque T_n est sans biais, son risque quadratique se réduit à sa variance :

$$\mathcal{R}(\theta, T_n) = Var_\theta(T_n).$$

Preuve : On a :

$$\begin{aligned} \mathcal{R}(\theta, T_n) &= E_\theta[(T_n - \theta)^2] = E_\theta[(T_n - E_\theta(T_n) + E_\theta(T_n) - \theta)^2] \\ &= E_\theta[(T_n - E_\theta(T_n))^2] + (E_\theta(T_n) - \theta)^2 + 2E_\theta[(T_n - E_\theta(T_n))(E_\theta(T_n) - \theta)] \\ &= Var_\theta(T_n) + \mathcal{B}_\theta^2(T_n) + 2\mathcal{B}_\theta(T_n)E_\theta[(T_n - E_\theta(T_n))] \\ &= Var_\theta(T_n) + \mathcal{B}_\theta^2(T_n) \end{aligned}$$

□

Exemple 4.4 (Avec une loi binomiale). Soient X_1, \dots, X_n i.i.d. $\mathcal{B}(\theta)$ avec $\theta \in]0; 1[$. L'estimateur empirique \bar{X}_n est sans biais pour θ et son risque quadratique

$$\begin{aligned} \mathcal{B}(\theta, \bar{X}_n) &= E_\theta[(\bar{X}_n - \theta)^2] \\ &= Var_\theta(\bar{X}_n) = \frac{Var_\theta(X_1)}{n} \\ &= \frac{\theta(1-\theta)}{n} \end{aligned}$$

$\mathcal{R}(\theta, \bar{X}_n)$ tend vers 0 lorsque la taille n augmente.

X_1 est un estimateur sans biais de θ car $E_\theta(X_1) = \theta$ et $\mathcal{R}(\theta, X_1) = Var_\theta(X_1) = \theta(1-\theta)$.

Définition 4.3. T_n est un estimateur de θ **convergeant en moyenne quadratique** si

$$\mathcal{R}(\theta, T_n) \xrightarrow{n \rightarrow +\infty} 0.$$

Exemple 4.5. X_1, \dots, X_n i.i.d. avec $X_1 \sim B(\theta), \theta \in]0, 1[$
Fréquence empirique

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

est un estimateur sans biais de θ . Son risque quadratique :

$$\mathcal{R}(\theta, \bar{X}_n) = \mathbb{E}[(\bar{X}_n - \theta)^2] = \text{Var}_\theta(\bar{X}_n) = \frac{\text{Var}_\theta(X_1)}{n} = \frac{\theta(1-\theta)}{n}.$$

$$\lim_{n \rightarrow \infty} \mathcal{R}(\theta, \bar{X}_n) = \lim_{n \rightarrow \infty} \frac{\theta(1-\theta)}{n} = 0 \text{ (on gagne en précision lorsque } n \text{ augmente).}$$

soit X_1 comme estimateur de θ , X_1 est un estimateur sans biais de θ car $\mathbb{E}_\theta(X_1) = \theta$ et $\mathcal{R}(\theta, X_1) = \text{Var}_\theta(X_1) = \theta(1-\theta)$.

Un estimateur T_n est dit convergent en moyenne quadratique vers θ si $\lim_{n \rightarrow \infty} \mathcal{R}(\theta, T_n) = 0$

Exemple 4.6 (Exemple précédant : modèle de Bernouilli). \bar{X}_n converge en moyenne quadratique car $\lim_{n \rightarrow \infty} \mathcal{R}(\theta, \bar{X}_n) = 0$

Définition 4.4 (Estimateur faiblement consistant). Soit T_n un estimateur de θ on dira que T_n est **faiblement consistant** si T_n converge en probabilité vers θ , signifie

$$\forall \theta \in \Theta, \forall \epsilon > 0, \lim_{n \rightarrow \infty} \mathbb{P}_\theta(|T_n - \theta| > \epsilon) = 0.$$

Définition 4.5 (Estimateur fortement consistant). T_n est un **estimateur fortement consistant** de θ si T_n converge presque sûrement vers θ signifie

$$\forall \theta \in \Theta, \mathbb{P}(\{\omega \text{ tq. } \lim_{n \rightarrow \infty} T_n(\omega) = \theta\}) = 1.$$

Proposition 4.3. Si T_n converge en moyenne quadratique vers θ alors T_n converge en probabilité vers θ .
En effet, en appliquant l'inégalité de Tchebychev, on a pour $\epsilon > 0$

$$\mathbb{P}(|T_n - \theta| > \epsilon) \leq \frac{\mathbb{E}((T_n - \theta)^2)}{\epsilon^2}.$$

Exemple 4.7 (du modèle de Bernouilli). X_1, \dots, X_n i.i.d. avec $X_1 \sim B(\theta), \theta \in]0, 1[$

— En appliquant la loi faible des grands nombre, on a

$$\bar{X}_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \mathbb{E}_\theta(X_1) = \theta.$$

(\bar{X}_n est faiblement consistante pour θ)

— En appliquant la loi forte des grand nombre, on a

$$\bar{X}_n \xrightarrow[n \rightarrow \infty]{p.s.} \mathbb{E}(X_1) = \theta.$$

(\bar{X}_n est fortement consistant pour θ)

— Autre façon de montrer le premier point. On a

$$\mathcal{R}(\theta, \bar{X}_n) = \text{Var}(\bar{X}_n) = \frac{\theta(1-\theta)}{n} \xrightarrow{n \rightarrow \infty} 0.$$

D'après la propriété précédente

$$\bar{X}_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \theta.$$

La variance $V_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ est un estimateur consistant de $\text{Var}_\theta(X_1)$ car on a

$$V_n^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2.$$

En appliquant la loi forte des grands nombres, on a

$$\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow[n \rightarrow \infty]{p.s.} \mathbb{E}(X_1^2).$$

$$\text{et } \bar{X}_n \xrightarrow[n \rightarrow \infty]{p.s.} \mathbb{E}_\theta(X_1).$$

D'où

$$V_n^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \xrightarrow[n \rightarrow \infty]{p.s.} \mathbb{E}_\theta(X_1^2) - \mathbb{E}(X_1) = \text{Var}_\theta(X_1).$$

5 Méthode de maximum vraisemblance

Voir diapo pour plus de précision sur l'exemple :

Exemple 5.1. $X_i = \begin{cases} 1 & \text{si la qualité de l'air dépasse le niveau 8 le jour } i \\ 0 & \text{sinon} \end{cases}$

$\theta = \mathbb{P}(X_i = 1)$ inconnu.

On observe $(x_1, x_2, \dots, x_n) = (0, 1, 1, 0, 1, 1, 1, 0, 0, 1)$

$$\begin{aligned} \mathbb{P}_\theta(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) &= P_\theta(X_1 = 0)P(X_2 = 1) \dots P(X_n = 1) \text{ (indépendance)} \\ &= \theta^6(1 - \theta)^4, \theta \in]0, 1[\end{aligned}$$

La valeur de θ qui rend maximale la probabilité d'observer $(0, 1, 1, \dots, 1)$ est $\hat{\theta} = \frac{6}{10}$

Cadre : $X_1, \dots, X_n = \mathbf{X}$ i.i.d. de loi $\mathbb{P}_\theta, \theta \in \Theta$. On note $f(x, \theta)$ la densité de X_1 si la loi de X_1 est continues $f(x, \theta) = \mathbb{P}(X_1 = x)$ si la loi de X_1 est discrète. On dispose des données (X_1, \dots, X_n)

Objectif : Trouver θ qui rend la réalisation (x_1, \dots, x_n) la plus probable .

Définition 5.1 (Vraisemblance d'un échantillon). On appelle **vraisemblance** de l'échantillon, la fonction L définie $\forall \theta \in \Theta$, par

$$\begin{aligned} L(x_1, \dots, x_n, \theta) &= \mathbb{P}_\theta(X_1 = x_1, \dots, X_n = x_n) \\ &= P(X_1 = x_1) * \dots * P(X_n = x_n) \text{ si de loi discrète} \\ &= f(x_1, \theta)f(x_2, \theta) \dots f(x_n, \theta) \text{ si } X \text{ a une loi continue} \end{aligned}$$

Remarque. — La vraisemblance est aléatoire. Une fois qu'on a une réalisation de l'échantillon, la vraisemblance ne dépend que de θ .

— Si pour deux valeurs du paramètre, on a $L(x_1, \dots, x_n, \theta_1) > L(x_1, \dots, x_n, \theta_2)$. On a θ_1 est plus vraisemblable pour θ_2 étant donnée la réalisation (x_1, \dots, x_n) de (X_1, \dots, X_n)

Exemple 5.2 (modèle de Bernouilli). X_1, \dots, X_n avec $X_1 \sim \mathcal{B}(\theta)$. Données : x_1, \dots, x_n avec $x_i \in \{0, 1\}$.

$$\begin{aligned} \mathbb{P}(X_i = 1) &= \theta \\ \mathbb{P}(X_i = 0) &= 1 - \theta \\ \mathbb{P}(X_i = x_i) &= \theta^{x_i}(1 - \theta)^{1-x_i}, x_i \in \{0, 1\} \end{aligned}$$

$$\begin{aligned} L(x_1, \dots, x_n, \theta) &= P(X_1 = x_1, \dots, X_n = x_n) \\ &= \prod_{i=1}^n \mathbb{P}_\theta(X_i = x_i) \text{ car indépendance} \\ &= \prod_{i=1}^n \theta^{x_i}(1 - \theta)^{1-x_i} \\ L(x_1, \dots, x_n, \theta) &= \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} \end{aligned}$$

Retour à ATMO : $L(0, 1, \dots, 1, 0) = \theta^6(1 - \theta)^4$

Exemple 5.3. Modèle de Poisson

(x_1, x_2, \dots, x_n) réalisation de (X_1, \dots, X_n) échantillon avec $X_1 \sim \mathcal{P}(\theta)$

$$\forall x \in \mathbb{N}, P_\theta(X = x) = e^{-\theta} \frac{\theta^x}{x!}.$$

La vraisemblance s'écrit

$$\begin{aligned} L(x_1, \dots, x_n, \theta) &= \prod_{i=1}^n P_\theta(X_i = x_i) \\ &= \prod_{i=1}^n e^{-\theta} \frac{\theta^{x_i}}{x_i!} \\ &= e^{-\theta} \frac{\theta^{x_1}}{x_1!} e^{-\theta} \frac{\theta^{x_2}}{x_2!} \dots e^{-\theta} \frac{\theta^{x_n}}{x_n!} \end{aligned}$$

Exemple 5.4. (x_1, x_2, \dots, x_n) réalisation de (X_1, \dots, X_n) échantillon avec $X_1 \sim \mathcal{N}(\theta, 1)$ ($E_\theta(X) = \theta, \text{var}(X) = 1$); La densité de X_i s'écrit

$$f(x, \theta) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(x-\theta)^2}.$$

La vraisemblance

$$\begin{aligned} L(x_1, \dots, x_n, \theta) &= \prod_{i=1}^n f(x_i, \theta) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(x_i-\theta)^2} \\ &= \frac{1}{(\sqrt{2\pi})^n} e^{-\frac{1}{2} \sum_{i=1}^n (x_i-\theta)^2} \end{aligned}$$

Exemple 5.5. (x_1, x_2, \dots, x_n) réalisation de (X_1, \dots, X_n) échantillon avec X_1 de densité $f(x, \theta) = \frac{\theta}{x^2} \mathbb{1}_{x \geq \theta}()$. La vraisemblance s'écrit

$$\begin{aligned} L(x_1, \dots, x_n, \theta) &= \prod_{i=1}^n f(x_i, \theta) \\ &= \frac{\theta}{x_1^2} \mathbb{1}_{x_1 \geq \theta} \dots \frac{\theta}{x_n^2} \mathbb{1}_{x_n \geq \theta} \\ &= \frac{\theta^n}{\prod_{i=1}^n x_i^2} \end{aligned}$$

Définition 5.2 (Estimateur du maximum de vraisemblance). On appelle estimateur pas maximum de vraisemblance (EMV) du paramètre θ un estimateur $\theta_n \in \Theta$ défini par

$$L((X_1, \dots, X_n, \theta)) = \sup_{\theta \in \Theta} L(X_1 \dots X_n, \theta).$$

Remarque. Comme la fonction $x \mapsto \log(x), x > 0$ est croissante strictement

$$\sup_{\theta \in \Theta} L(x_1 \dots x_n, \theta) = \sup_{\theta \in \Theta} \log L(x_1 \dots x_n, \theta) = \begin{cases} \sup_{\theta \in \Theta} \sum_{i=1}^n \log P_\theta(X_i = x_i) & \text{cas discret} \\ \sup_{\theta \in \Theta} \sum_{i=1}^n \log f(x_i, \theta) & \text{cas continue} \end{cases}.$$

Définition 5.3 (Log-vraisemblance). La fonction définie par

$$l(x_1, \dots, x_n, \theta) = \log L(\mathbf{X}, \theta) = \begin{cases} \sup_{\theta \in \Theta} \sum_{i=1}^n \log P_\theta(X_i = x_i) & \text{cas discret} \\ \sup_{\theta \in \Theta} \sum_{i=1}^n \log f(x_i, \theta) & \text{cas continue} \end{cases}.$$

est appelée **log-vraisemblance**

Exemple 5.6 (Modèle de Bernouilli). $L(x_1, \dots, x_n, \theta) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}$.
La log-vraisemblance vaut

$$\begin{aligned} l(x_1, \dots, x_n, \theta) &= \log L(x_1, \dots, x_n, \theta) \\ &= \log(\theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}) \\ &= \log \theta^{\sum_{i=1}^n x_i} + \log((1 - \theta)^{n - \sum_{i=1}^n x_i}) \\ l(x_1, \dots, x_n, \theta) &= \left(\sum_{i=1}^n x_i\right) \log \theta + \left(n - \sum_{i=1}^n x_i\right) \log(1 - \theta) \end{aligned}$$

$$\begin{aligned} \frac{\partial l(x_1, \dots, x_n, \theta)}{\partial \theta} &= \frac{\sum_{i=1}^n x_i}{\theta} - \frac{n - \sum_{i=1}^n x_i}{1 - \theta} \\ &= \frac{(1 - \theta) \sum_{i=1}^n x_i - (n - \sum_{i=1}^n x_i) \theta}{\theta(1 - \theta)} \\ &= \frac{\sum_{i=1}^n x_i (n\theta)}{\theta(1 - \theta)} \end{aligned}$$

$$\begin{aligned} \frac{\partial l(x_1, \dots, x_n, \theta)}{\partial \theta} &= 0 \Leftrightarrow \sum_{i=1}^n x_i (n\theta) = 0 \\ \theta^* &= \frac{1}{n} \sum_{i=1}^n x_i \end{aligned}$$

l est maximale lorsque $\theta = \theta^* = \frac{1}{n} \sum_{i=1}^n x_i$
 $\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n X_i$ (variance empirique) est l'ENV de θ (variance empirique)

Exemple 5.7 (Modèle de Poisson). La vraisemblance $L(x_1, \dots, x_n, \theta) = e^{-n\theta} \frac{\theta^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n (x_i!)}$, $x_i \in \mathbb{N}$.
La log-vraisemblance :

$$\begin{aligned} l(x_1, \dots, x_n, \theta) &= \log L(x_1, \dots, x_n, \theta) \\ &= \log e^{-n\theta} + \log \theta^{\sum_{i=1}^n x_i} - \log \prod_{i=1}^n (x_i!) \\ &= -n\theta + \sum_{i=1}^n x_i \log \theta - \log \prod_{i=1}^n (x_i!) \end{aligned}$$

Dérivé :

$$\begin{aligned} \frac{\partial l(x_1, \dots, x_n, \theta)}{\partial \theta} &= -n + \frac{\sum_{i=1}^n x_i}{\theta} \\ &= \frac{-n\theta + \sum_{i=1}^n x_i}{\theta} \end{aligned}$$

$$\begin{aligned} \frac{\partial l(x_1, \dots, x_n, \theta)}{\partial \theta} &= 0 \Leftrightarrow -n\theta + \sum_{i=1}^n x_i = 0 \\ \theta^* &= \frac{1}{n} \sum_{i=1}^n x_i \end{aligned}$$

Et :

$$\frac{\partial^2 l(x_1, \dots, x_n, \theta)}{\partial \theta^2} = \frac{1}{\theta^2} \sum_{i=1}^n x_i < 0 \text{ car } x_i \in \mathbb{N}.$$

l est maximale lorsque $\theta = \frac{1}{n} \sum_{i=1}^n x_i$
 $\Rightarrow \hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n x_i$ (moyenne empirique) est l'ENV pour θ

Exemple 5.8 (Loi normale). (x_1, x_2, \dots, x_n) réalisation de (X_1, \dots, X_n) échantillon avec $X_1 \sim \mathcal{N}(\theta, 1)$.
La vraisemblance :

$$L(x_1, \dots, x_n, \theta) = \frac{1}{(\sqrt{2\pi})^n} e^{-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2}.$$

La log-vraisemblance s'écrit :

$$l(x_1, \dots, x_n, \theta) = \log((2\pi)^n) - \frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2.$$

$$\begin{aligned} \frac{\partial l(x_1, \dots, x_n, \theta)}{\partial \theta} &= +\frac{1}{2} * 2 \sum_{i=1}^n (x_i - \theta) \\ &= \sum_{i=1}^n (x_i) - n\theta \\ &= 0 \Leftrightarrow \theta^* = \frac{1}{n} \sum_{i=1}^n x_i \end{aligned}$$

$\theta_n = \frac{1}{n} \sum_{i=1}^n X_i$ est l'EMV pour θ

Exemple 5.9 (Loi random de toute à l'heure). (x_1, x_2, \dots, x_n) réalisation de (X_1, \dots, X_n) échantillon avec X_1 de densité $f(x, \theta) = \frac{\theta}{x^2} \mathbb{1}_{x \geq \theta}()$.

La vraisemblance vaut

$$\frac{\theta^n}{\prod_{i=1}^n x_i^2} \mathbb{1}_{\min(x_i) \geq \theta}.$$

Note. Si on dérive on vas tombé sur une dérivé partiel type $\frac{n}{\theta}$ dont on ne peux pas dérivé en theta encore

L atteint son maximum lorsque $\theta^* = \min_{1 \leq i \leq n} (x_i)$, $\hat{\theta}_n = \min_{1 \leq i \leq n} (X_i)$ est l'ENV pour θ

Exemple 5.10 (Modèle Gaussien). X_1, \dots, X_n échantillon de taille n où $X_i \sim \mathcal{N}(1, \sigma^2)$, $E(X_i) = 1$, $var(X_i) = \sigma^2 = \theta$.

La densité de X_i vaut

$$f(x, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2} (x_1 - 1)^2}.$$

La vraisemblance vaut

$$\begin{aligned} L(x_1, \dots, x_n, \sigma^2) &= \prod_{i=1}^n f(x_i, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2} (x_i - 1)^2} \\ &= \frac{1}{(\sqrt{2\pi\sigma^2})^n} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - 1)^2} \end{aligned}$$

La log vraisemblance

$$\begin{aligned} l(x_1, \dots, x_n, \sigma^2) &= \log L((x_1, \dots, x_n, \sigma^2)) \\ &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - 1)^2 \end{aligned}$$

La dérivé

$$\begin{aligned} \frac{\partial l}{\partial \sigma^2}(x_1, \dots, x_n, \sigma^2) &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - 1)^2 \\ &= \frac{-n\sigma^2 + \sum_{i=1}^n (x_i - 1)^2}{2\sigma^4} \\ \frac{\partial l}{\partial \sigma^2}(x_1, \dots, x_n, \sigma^2) &= 0 \Leftrightarrow -n\sigma^2 + \sum_{i=1}^n (x_i - 1)^2 = 0 \\ &\Leftrightarrow \sigma^{*2} = \frac{1}{n} \sum_{i=1}^n (x_i - 1)^2 \end{aligned}$$

l est maximale lorsque $\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - 1)^2$

Conclusion $\hat{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - 1)^2$ est l'EMV de σ^2

Exemple 5.11. X_1, \dots, X_n échantillon de taille n où $X_i \sim \mathcal{N}(m, \sigma^2)$, $E(X_i) = m$, $\text{var}(X_i) = \sigma^2 = \theta$ avec m et σ^2 inconnu. $\theta = (m, \sigma^2)$

La densité de X_i vaut :

$$f(x, m, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_1-m)^2}.$$

La vraisemblance vaut

$$\begin{aligned} L(x_1, \dots, x_n, \sigma^2) &= \prod_{i=1}^n f(x_i, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i-m)^2} \\ &= \frac{1}{(\sqrt{2\pi\sigma^2})^n} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i-m)^2} \end{aligned}$$

La log vraisemblance

$$\begin{aligned} l(x_1, \dots, x_n, \sigma^2) &= \log L((x_1, \dots, x_n, \sigma^2)) \\ &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m)^2 \end{aligned}$$

Trouver les points critiques :

$$\begin{cases} \frac{\partial l}{\partial m}(x_1 \dots x_n \sigma^2) = 0 \\ \frac{\partial l}{\partial \sigma^2}(x_1 \dots x_n \sigma^2) = 0 \end{cases} \Leftrightarrow \begin{cases} \sum_{i=1}^n (x_i - m) = 0 \\ -\frac{n}{\sigma^2} + \frac{\sum_{i=1}^n (x_i - m)^2}{\sigma^4} = 0 \end{cases} \Leftrightarrow \begin{cases} \sum_{i=1}^n (x_i - m) = 0 \\ \sum_{i=1}^n (x_i - m)^2 - n\sigma^2 = 0 \end{cases} \Leftrightarrow \begin{cases} m^* = \frac{1}{n} \sum_{i=1}^n x_i \\ \sigma^{*2} = \frac{1}{n} \sum_{i=1}^n (x_i - m^*)^2 \end{cases}.$$

Pour vérifier que (m^*, σ^{*2}) est un maximum, il faut montrer que

$$\det \begin{pmatrix} \frac{\partial^2 l(m^*, \sigma^{*2})}{\partial m^2} & \frac{\partial^2 l(m^*, \sigma^{*2})}{\partial m \partial \sigma^2} \\ \frac{\partial^2 l(m^*, \sigma^{*2})}{\partial \sigma^2 \partial m} & \frac{\partial^2 l(m^*, \sigma^{*2})}{\partial \sigma^4} \end{pmatrix} > 0 \text{ avec } \frac{\partial^2 l(m^*, \sigma^{*2})}{\partial m^2} < 0, \frac{\partial^2 l(m^*, \sigma^{*2})}{\partial \sigma^4} < 0.$$

$$\frac{\partial^2 l(m, \sigma^2)}{\partial m^2} = -\frac{n}{\sigma^2}.$$

$$\begin{aligned} \frac{\partial^2 l(m, \sigma^2)}{\partial \sigma^4} &= \frac{\partial}{\partial \sigma^2} \left[-\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - m)^2 \right] \\ &= \frac{n}{2\sigma^4} - \frac{1}{\sigma^6} \sum_{i=1}^n (x_i - m)^2 \\ &= \frac{n}{2\sigma^{*4}} - \frac{1}{\sigma^{*6}} \sum_{i=1}^n (x_i - m^*)^2 \\ &= \frac{n}{2\sigma^{*4}} - \frac{1}{\sigma^{*6}} n\sigma^{*2} \\ &= \frac{n}{2\sigma^{*4}} - \frac{n\sigma^{*2}}{\sigma^{*6}} \\ &= \frac{n}{2\sigma^{*4}} - \frac{n}{\sigma^{*4}} \\ &= -\frac{n}{2\sigma^{*4}} \end{aligned}$$

$$\frac{\partial^2 l}{\partial m \partial \sigma^2}(m^*; \sigma^{*2}) = 0 \text{ (A vérifier!).}$$

Conclusion

$$\text{Hess}(m^*, \sigma^{*2}) = \begin{pmatrix} -\frac{n}{\sigma^{*2}} & 0 \\ 0 & -\frac{n}{2\sigma^{*4}} \end{pmatrix}, \det \text{Hess}(m^*, \sigma^{*2}) = \frac{n}{\sigma^{*2}} \frac{n}{2\sigma^{*4}} > 0, -\frac{n}{\sigma^{*2}} < 0 \text{ et } -\frac{n}{2\sigma^{*4}} < 0.$$

$\Rightarrow (m^*, \sigma^{*2})$ est un maximum **local** de l

$(\frac{1}{n} \sum_{i=1}^n X_i, \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2) = (\bar{X}_n, V_n^2)$ est l'ENV de (m, σ^2)

Remarque. 1. L'ENV peut être **biaisé**

2. L'ENV n'est pas toujours **unique**

3. L'ENV peut ne pas exister